

MPEI

Soma e Combinação Linear de Variáveis Aleatórias
Funções de Variáveis Aleatórias

Aplicação: Contadores Estocásticos

Soma de variáveis aleatórias

- Vimos anteriormente um exemplo de soma de variáveis de Bernoulli
 - Na apresentação da Distribuição Binomial
- O que acontece se somarmos outros tipos de variáveis?
- Tentar dar resposta a esta questão é o objectivo desta aula

Motivação

- Se somarmos duas variáveis aleatórias X_1 e X_2 **quais as características** da variável aleatória $S = X_1 + X_2$?
 - Em termos de momentos ?
 - Em especial média e variância
 - Em termos de função de distribuição ?
- E no caso geral $S_n = X_1 + X_2 + \cdots + X_n$?

Média da soma de n variáveis

- Sejam X_1, X_2, \dots, X_n , n variáveis aleatórias e $S_n = X_1 + X_2 + \dots + X_n$ a sua soma
- Teorema: **A média da soma de n variáveis é igual à soma das médias**
- Demonstração

$$\begin{aligned} E[S_n] &= \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} \left(\sum_{j=1}^n x_j \right) f_{X_1 \dots X_n}(x_1, \dots, x_n) dx_1 \dots dx_n = \\ &= \sum_{j=1}^n \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} x_j f_{X_1 \dots X_n}(x_1, \dots, x_n) dx_1 \dots dx_n = \\ &= \sum_{j=1}^n \int_{-\infty}^{+\infty} x_j f_{X_j}(x_j) dx_j = \sum_{j=1}^n E[X_j] \end{aligned}$$



Variância da soma de n variáveis

- Considerando da mesma forma $S_n = X_1 + X_2 + \dots + X_n$:
- Teorema: **A variância da soma de n variáveis aleatórias é dada pela soma de todas as variâncias e covariâncias**

$$Var(S_n) = \sum_{i=1}^n Var(X_i) + \sum_{j=1}^n \sum_{\substack{k=1 \\ j \neq k}}^n Cov(X_j, X_k)$$

- Demonstração:

$$\begin{aligned} Var(S_n) &= E \left[\sum_{j=1}^n (X_j - E[X_j]) \sum_{k=1}^n (X_k - E[X_k]) \right] = \\ &= \sum_{j=1}^n \sum_{k=1}^n E[(X_j - E[X_j]) (X_k - E[X_k])] \end{aligned}$$



Variância da soma de n variáveis

- Se as variáveis **são independentes**,
 $Cov(X_j, X_k) = 0$, para todo o $j \neq k$, pelo que:
- **$Var(S_n) = \sum_{i=1}^n Var(X_i)$**
– **Variância da soma igual a soma das variâncias**
- Se para além de independentes forem **identicamente distribuídas (IID)**
e tivermos $E[X_i] = \mu$ e $Var(X_i) = \sigma^2, i = 1, 2, \dots, n$
a média e variância da soma são dadas por:
- $E[S_n] = n \mu$ e $Var(S_n) = n \sigma^2$



Função de distribuição da soma de 2 variáveis aleatórias independentes

- Caso discreto (2 v.a. Discretas X e Y)

- Fazendo $Z = X + Y$

- $p_Z(z) = P(X + Y = z)$

$$= \sum_{\{(x,y)|x+y=z\}} P(X = x, Y = y)$$

$$= \sum_x P(X = x, Y = z - x)$$

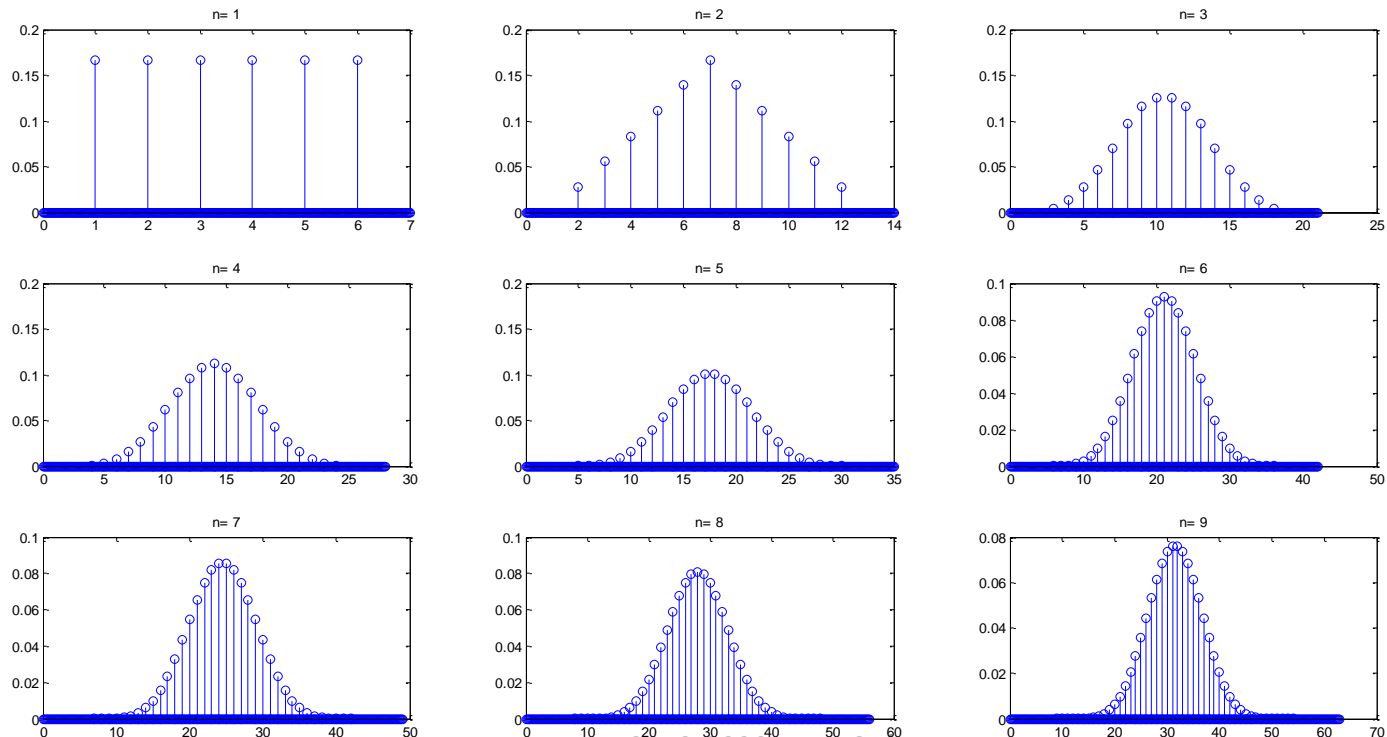
$$= \sum_x p_X(x) p_Y(z - x) \quad ; \text{ devido à indep.}$$

$$= p_X(x) * p_Y(z)$$

- Que é a **convolução** discreta de p_X e p_Y










Exemplo (em Matlab)

- Usando `conv()` e a pmf relativa à variável X correspondente ao lançamento de um dado honesto ($n=1, 2, \dots, 9$)



Outro exemplo

- Sendo X relativa ao número de caras num lançamento de moeda não honesta
– com probabilidade de cara = 0,6



Caso contínuo

- Sendo X e Y independentes e contínuas
- Fazendo novamente $Z = X + Y$
- Para obter a função densidade prob. de Z , primeiro obtém-se a f. densidade conjunta de X e Z e depois integra-se

$$\begin{aligned} F_{Z|X}(z|x) &= \mathbf{P}(Z \leq z | X = x) = \mathbf{P}(X + Y \leq z | X = x) = \mathbf{P}(x + Y \leq z | X = x) = \mathbf{P}(Y \leq z - x | X = x) \\ &= \mathbf{P}(Y \leq z - x) \quad \text{using the independence of } X \text{ and } Y \\ &= F_Y(z - x) \end{aligned}$$

$$f_{Z|X}(z|x) = \frac{d}{dz} F_{Z|X}(z|x) = \frac{d}{dz} F_Y(z - x) = f_Y(z - x)$$

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{\infty} f_{X,Z}(x,z) dx = \int_{-\infty}^{\infty} f_X(x) f_{Z|X}(z|x) dx \\ &= \int_{-\infty}^{\infty} f_X(x) f_Y(z - x) dx \equiv f_X * f_Y(z) \end{aligned}$$

Obtém-se através da
convolução, agora contínua

- Para mais informação, ver, por exemplo:
- https://engineering.purdue.edu/~ipollak/ece302/SPRING12/notes/23_GeneralRVs-8_Sums.pdf

Combinações lineares de variáveis aleatórias

- Os **resultados anteriores generalizam-se** facilmente para o caso de termos uma soma pesada (combinação linear) $Y_n = c_1X_1 + c_2X_2 + \dots + c_nX_n$
 - Em que c_1, c_2, \dots, c_n são constantes
- $E[Y_n] = c_1E[X_1] + c_2E[X_2] + \dots + c_nE[X_n]$
- $Var(Y_n) = \sum_{i=1}^n c_i^2 Var(X_i) + \sum_i \sum_{j (\neq i)} c_i c_j Cov(X_i, X_j)$
- **Se independentes** $Var(Y_n) = \sum_{i=1}^n c_i^2 Var(X_i)$

Exemplo de aplicação

- Um semicondutor tem 3 camadas.
- Se a espessura das várias camadas tiver uma variância de 25, 40 e 30 nanómetros quadrados, qual a variância da espessura das 3 camadas ?
- Considerando X_1, X_2, X_3 como as espessuras das camadas e independência
- $Var(X_1 + X_2 + X_3) = Var(X_1) + var(X_2) + var(X_3) = 95$
- Mostrando a propagação das variâncias de todas as camadas para o resultado final
 - Os problemas somam-se ☹

Funções de variáveis aleatórias

A soma (simples ou pesada) de variáveis aleatórias é um caso particular

Funções de v. a. múltiplas

- Muitas vezes encontramos **problemas em que temos uma transformação das v. a.** X_1, X_2, \dots, X_n que produz variáveis aleatórias Y_1, Y_2, \dots, Y_m
- O caso mais simples é termos uma função escalar de várias variáveis aleatórias

$$Z = g(X_1, X_2, \dots, X_n)$$

- A função de distribuição acumulada de Z é determinada como sabemos calculando a probabilidade do conjunto $\{Z \leq z\}$

i.e. A região R_z do espaço n -dimensional tal que

$$R_z = \{\mathbf{x}: g(\mathbf{x}) \leq z\} \quad \mathbf{x} = (x_1 \ x_2 \ \dots \ x_n)$$

- Logo

$$- F_Z(z) = \int_{\mathbf{x} \in R_z} \dots \int f_X(\mathbf{x}) d\mathbf{x}$$

Expectância de funções de v. aleatórias

- Expectância de uma função de 2 var. aleatórias

$$Z = g(X, Y)$$

$$E[Z] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f_{X,Y}(x, y) dx dy$$

- Para o caso de variáveis discretas :

$$- E[Z] = \sum_i \sum_n g(x_i, y_n) p_{X,Y}(x_i, y_n)$$

- Resultado generalizável para uma função com um número arbitrário de variáveis aleatórias

$$Z = g(\mathbf{X}) \quad \text{em que } \mathbf{X} \text{ (bold) é um vector}$$

$$E[Z] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}$$

Exemplo

- $Z = g(X, Y) = X + Y$ *i.e.* Soma de 2 v.a.
- $E[Z] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x + y) f_{X,Y}(x, y) dx dy$
- $= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x f_{X,Y}(x, y) dx dy + \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y f_{X,Y}(x, y) dx dy$
- $= \int_{-\infty}^{\infty} x f_X(x) dx + \int_{-\infty}^{\infty} y f_Y(y) dy$
- $= E(X) + E(Y)$
- Resultado válido quer as variáveis **sejam independentes ou não**
- Mostra (conjuntamente com a propriedade de escala, $E(aX) = aE(X)$) que a expectância é um **operador linear**

Momentos de funções de variáveis aleatórias

- Momento de ordem n de uma função escalar de um vector aleatório:

$Z = g(\mathbf{X})$ em que \mathbf{X} (bold) é um vector

$$E[\mathbf{Z}^n] = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \mathbf{g}^n(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}$$

- Aplicando para obter a variância temos:
- $\text{Var}[Z] = E[Z^2] - E^2[Z]$
- $= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \mathbf{g}^2(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} - \left(\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \mathbf{g}(\mathbf{x}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} \right)^2$

Média de variáveis aleatórias

- E se a função aplicada a um vetor de n variáveis aleatórias for a média dessas variáveis?
- Interessa-nos em especial o caso em que essas n variáveis são independentes e identicamente distribuídas (IID)

Valor esperado da Média

- Se criarmos a variável aleatória relativa à média de n variáveis IID X_i ,

$$\mathbf{M}_n = \frac{S_n}{n},$$


- e assumindo $E[X_i] = \mu$ e $Var(X_i) = \sigma^2$
- teremos :

- $E[\mathbf{M}_n] = E\left[\frac{S_n}{n}\right]$

- $= \frac{\sum_i E[X_i]}{n}$

- $= E[X_i] = \mu$

Variância da Média

- $\text{Var}(M_n) = ?$
 - $\text{Var}[M_n] = \text{Var}\left(\frac{S_n}{n}\right)$
 - $= \frac{1}{n^2} \frac{\sum_i \text{Var}[X_i]}{1}$
 - $= \frac{\text{Var}(X_i)}{n} = \frac{\sigma^2}{n}$
- 
- À medida que se aumenta o número de experiências vai diminuindo a variância da estimativa da média

Aplicação interessante de soma de variáveis aleatórias

Contadores estocásticos

Motivação

- Evitar contadores grandes quando o volume de dados é grande
 - Por exemplo: na contagem de células
- Como um contador de n bits contará no máximo até 2^n eventos, será este o limite a ultrapassar

Primeira solução

- Para duplicar o número de eventos que se podem contar, incrementa-se o contador com probabilidade $1/2$ cada vez que ocorre um evento
- *A ideia é incrementar o contador metade das vezes (em média)*

...

- Com base na função `rand()` podemos agora tomar decisões aleatórias com probabilidade $1/2$ e portanto construir uma função para incrementar (ou não) o contador:

```
if (rand() < 0.5) then  
    incrementar_contador  
endif
```

Em Matlab

- Podemos facilmente simular o resultado após 100 eventos:

% gera 100 var aleatórias indep em [0,1]

x = rand(1, 100);

% calcular quantas são < 0.5

n = sum(x < 0.5);

- n representará o valor do contador após os 100 eventos



contadores1.m

Qual é o valor médio do contador após k eventos?

- O contador é uma variável aleatória, determinada por uma sucessão de experiências aleatórias
- Associando uma variável aleatória a cada evento, de forma a representá-lo probabilisticamente
- Seja X_i a variável aleatória que representa o incremento i , com valor 1 se o contador foi incrementado, e valor zero caso contrário.
- Como $P(X_i = 0)$ e $P(X_i = 1)$ são iguais a $1/2$, tem-se
- $$E[X_i] = 0 \times P(X_i = 0) + 1 \times P(X_i = 1) = \frac{1}{2}$$

Valor médio


- O valor do contador após k eventos é a soma dos k incrementos, $S = X_1 + X_2 + \cdots + X_k$
- E o valor médio:
- $E[S] = E[X_1 + X_2 + \cdots + X_k]$
- $= E[X_1] + E[X_2] + \cdots + E[X_k]$
- $= \frac{1}{2} + \cdots + \frac{1}{2} = \frac{k}{2}$
- Como o valor médio do contador após k eventos é $k/2$, o número de eventos pode ser estimado através do dobro do número registado pelo contador

Variância

- A variância de um qualquer dos X_i é
- $Var(X_i) = E[X_i^2] - (E[X_i])^2$
- $E[X_i^2] = 0^2 \times P(X_i = 0) + 1^2 \times P(X_i = 1)$
- $= \frac{1}{2}$
- $Var(X_i) = \frac{1}{2} - \frac{1}{4} = \frac{1}{4}$

Variância (continuação)

- Como as variáveis X_i são independentes, a variância de S é
- $Var(S) = Var(X_1 + X_2 + \dots + X_k)$
- $= Var(X_1) + Var(X_2) + \dots + Var(X_k)$
- $= \frac{1}{4} + \dots + \frac{1}{4} = \frac{k}{4}$
- O que implica $\sigma = \frac{\sqrt{k}}{2}$
- Para **n=10000** teremos:
 - média 5000
 - desvio padrão 50



Comparar com
simulação
(contadores1.m)

Distribuição de probabilidade

- Pode calcular-se a probabilidade de, após k eventos, o valor do contador ser n .
- Fixemos $k = 4$:
- Teremos X_1, X_2, X_3 e X_4
 - Variáveis binárias que descrevem se o contador é incrementado ou não após o evento 1,2,3 e 4
- O que nos dá 16 possibilidades (2^4)

X_1	X_2	X_3	X_4	valor do contador
0	0	0	0	0
0	0	0	1	1
0	0	1	0	1
0	0	1	1	2
0	1	0	0	1
0	1	0	1	2
0	1	1	0	2
0	1	1	1	3
1	0	0	0	1
1	0	0	1	2
1	0	1	0	2
1	0	1	1	3
1	1	0	0	2
1	1	0	1	3
1	1	1	0	3
1	1	1	1	4

• É agora fácil determinar as probabilidades, por contagem:

- $p(0) = \frac{1}{16}$
- $p(1) = \frac{4}{16}$
- $p(2) = \frac{6}{16}$
- $p(3) = \frac{4}{16}$
- $p(4) = \frac{1}{16}$

Generalizando

- Sendo p a probabilidade de incrementar e $1 - p$ a probabilidade de não incrementar ...
- A probabilidade de observar uma soma igual a n após k experiências é:

$$p(n) = \binom{k}{n} p^n (1 - p)^{k-n}$$

Variante 1

- Como proceder para **alargar mais a gama** do contador?
- Imaginemos, por exemplo, que se quer multiplicar por 64 essa gama. A solução natural é incrementar com probabilidade $1/64$ em vez de $\frac{1}{2}$
- O valor médio de X_i será agora $\frac{1}{64}$
- $E[S] = \dots = \frac{k}{64}$
- Neste caso, o número de eventos pode ser estimado por $64n$, sendo n o valor do contador

Segunda solução

- Neste caso o contador é incrementado com probabilidade cada vez menor à medida que o seu valor aumenta:
- quando o contador contém n , a probabilidade de um incremento é 2^{-n}

<i>Eventos</i>	<i>Valor do contador</i>	<i>Número de eventos</i>
x	1	1
x	2	3
x		
x		
x	3	7
x		
x		
x		
x		
x		
x		
x	4	15
x		

Para mais informação

- Ver notas do ano letivo 2014/2015 de autoria do Prof. Paulo Jorge Ferreira
 - (disponíveis no elearning da UC)